

강원지역혁신플랫폼

# 기계학습

Machine Learning

기계학습의 종류





## ▶ 학습목표

📁 기계학습의 종류 및 개념을  
구체적으로 설명할 수 있습니다.





# 01 | 기계학습의 종류



## 기계학습의 종류

△ 사람의 감독하에 훈련하는 것인지 아닌지에 따라 분류

◆ 이 범주는 기계학습 시스템을 “학습하는 동안의 감독 형태나 정보량”에 따라 분류할 수 있음

➤ 지도   ➤ 비지도   ➤ 준지도   ➤ 강화학습

학습하는 동안의 감독 형태나 정보량에 따른 분류





# 01 | 기계학습의 종류



## 기계학습의 종류

⚙️ 실시간으로 점진적인 학습을 하는 것인지 아닌지에 따른 분류

- ◆ 온라인 학습 (미니배치 학습)
- ◆ 배치 학습

⚙️ 단순히 알고 있는 데이터 포인트와 새 데이터 포인트를 비교하는 것인지

- ◆ 또는, 훈련 데이터 셋에서 패턴을 발견하여 예측 모델을 만드는지에 따른 분류
  - 사례 기반 학습
  - 모델 기반 학습



# 01 | 기계학습의 종류



## 기계학습의 종류

- △ 위의 범주들은 서로 배타적이지 않으며 원하는 대로 연결할 수 있음
  - ◆ 예를 들어 최첨단 스팸 필터가 심층 신경망 모델을 사용해 스팸 메일과 스팸이 아닌 메일로부터 실시간으로 학습할 수도 있음
    - 그러면, 이 시스템은 온라인이고, 모델 기반이며 지도학습 시스템임



## 02 | 지도학습



### 지도학습(Supervised Learning)

지도학습에는 알고리즘에 주입하는 **훈련 데이터**에 레이블(Label)이라는 원하는 답이 포함되어야 함

훈련 데이터 집합



스팸 분류를 위한 레이블된 훈련 데이터 집합





## 02 | 지도학습

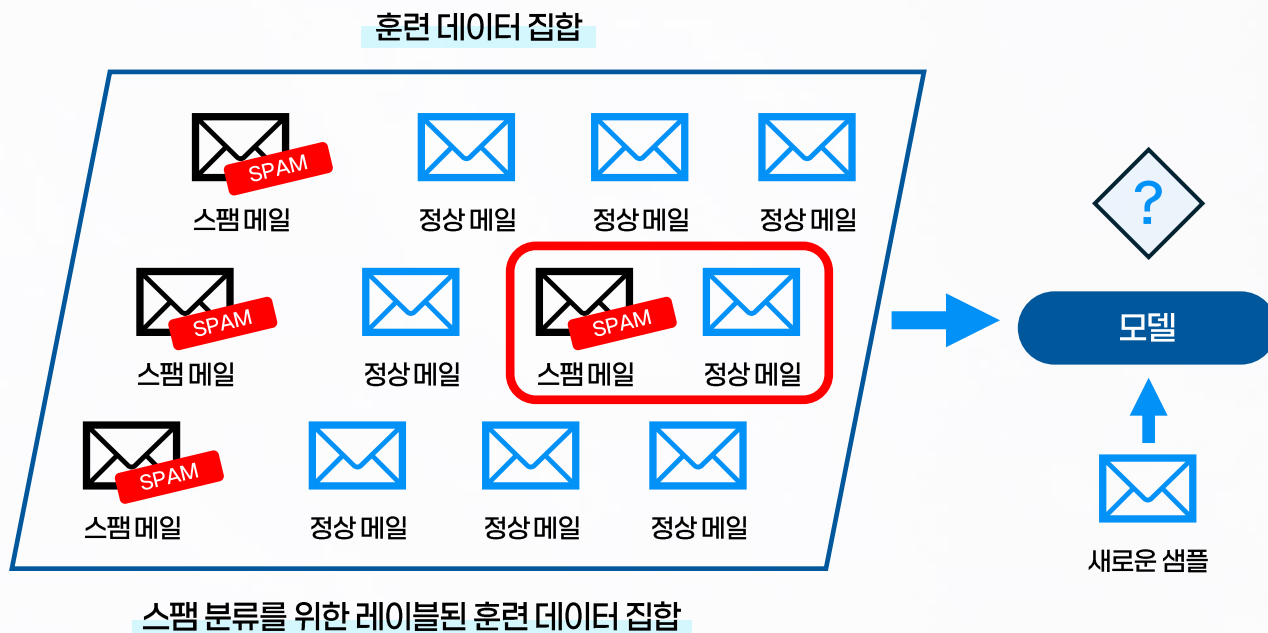
### 지도학습(Supervised Learning)

분류(Classification)는 전형적인 지도학습 작업임

◆ 분류의 좋은 예가 스팸 필터 시스템임

➢ 스팸 필터는 많은 메일 샘플과 소속 정보(스팸인지 아닌지)로 훈련됨

— 그리고, 어떻게 새 메일을 분류할지 학습해야 함





## 02 | 지도학습



### 지도학습(Supervised Learning)

△ 회귀(regression)는 전형적인 지도학습 작업임

- ◆ 회귀는 예측 변수(Predictor Variable)라 불리는 특성(Feature)을 사용해 중고차 가격 같은 타겟 수치를 예측함
  - ▶ 여기서 특성의 예로 주행거리, 연식, 브랜드 등을 예로 들 수 있음
- ◆ 중고차 가격 예측 시스템을 훈련하려면 예측 변수와 레이블(중고차 가격)이 포함된 중고차 데이터가 많이 필요함

- ❖ 기계학습에서 속성(attribute)은 데이터 타입을 말함
- ❖ 특성은 문맥에 따라 여러 의미를 갖지만 일반적으로 속성과 값이 합쳐진 것을 의미함 (예를 들면 주행거리 = 17,000km)






## 02 | 지도학습



### 지도학습(Supervised Learning)

- ◆ 아래의 그림은 **선형 회귀 모델에 새로운 샘플 특성으로 값을 예측하는 것**을 나타냄
  - 일반적으로 **입력 특성이 여러 개** 있음





## 02 | 지도학습



### 지도학습(Supervised Learning)

다음은 대표적인 지도 학습 알고리즘들임

- ◆ K-최근접 이웃(k-Nearest Neighbors)
- ◆ 선형 회귀(Linear Regression)
- ◆ 로지스틱 회귀(Logistic Regression)
- ◆ 서포트 벡터 머신(SVM, Support Vector Machine)
- ◆ 결정 트리(Decision Tree)
- ◆ 랜덤 포레스트(Random Forest)
- ◆ 신경망(Neural Network)



## 03 | 비지도 학습




### 비지도 학습(Unsupervised Learning)

비지도 학습은 지도 학습에서 필요했던 레이블이 필요하지 않으며 시스템이 아무런 도움 없이 학습해야 함

즉, 말 그대로 훈련 데이터에 레이블이 없음

훈련 데이터 집합



비지도 학습에서 레이블이 없는 훈련 데이터 집합



## 03 | 비지도 학습



### 비지도 학습(Unsupervised Learning)

△ 다음은 대표적인 **비지도 학습 알고리즘**임

#### ◆ 군집(Clustering)

- K-평균(k-Means)
- 계층 군집 분석(HCA, Hierarchical Cluster Analysis)
- 기댓값 최대화(Expectation Maximization)
- 밀도 기반 클러스터링(DBSCAN, Density-Based Spatial Clustering of Applications with Noise)

#### ◆ 이상치 탐지(Outlier Detection)와 특이치 탐지(Novelty Reduction)

- 원 클래스 SVM(One Class Support Vector Machine)
- 아이솔레이션 포레스트(isolation forest)



## 03 | 비지도 학습



### 비지도 학습(Unsupervised Learning)

- ◆ 시각화(Visualization)와 차원 축소(Dimensionality Reduction)
  - 주성분 분석(PCA, Principal Component Analysis)
  - 커널 PCA(Kernel PCA)
  - 지역적 선형 임베딩(LLE, Locally-Linear Embedding)
  - t-SNE(t-distributed Stochastic Neighbor Embedding)
- ◆ 연관 규칙 학습(Association Rule Learning)
  - 어프라이어리(Apriori)
  - 이클렛(Eclat)





## 03 | 비지도 학습



### 비지도 학습(Unsupervised Learning)

#### △ 계층 군집 알고리즘의 사용 예시


◆ 예를 들어 블로그 방문자에 대한 데이터가 많이 있다고 가정해 보자.

➢ 비슷한 방문자들을 그룹으로 묶기 위해 군집 알고리즘을 적용함

➢ 하지만, 방문자가 어떤 그룹에 속하는지 알고리즘에 알려줄 수 있는 데이터 포인트가 없음

➢ 알고리즘이 스스로 방문자 사이의 연결고리를 찾음

➔ 계층 군집 알고리즘을 사용하면 각 그룹을 더 작은 그룹으로 세분화할 수 있음



[비슷한 방문자 그룹으로  
묶기 위한  
군집 알고리즘]




## 03 | 비지도 학습



### 비지도 학습(Unsupervised Learning)

- ◆ 계층 군집을 시각화하는 도구인 **덴드로그램**은 **다차원 데이터셋**을 **처리**할 수 있음
  - **덴드로그램**에서 **데이터 포인트**는 **맨 아래** 나타남
    - **각각**이 **하나**의 **클러스터**인 이 **포인트**들을 **잎**이라고 하며, **잎**을 **포함**하는 **트리**가 만들어짐





## 03 | 비지도 학습

### 비지도 학습(Unsupervised Learning)


시각화(Visualization) 알고리즘의 사용 예시

◆ 레이블이 없는 대규모의 고차원 데이터를 넣으면 도식화가 가능한 2D 또는 3D 표현을 만들어줌

➤ 아래의 그림은 t-SNE 알고리즘을 적용해 MNIST 손글씨 숫자 데이터셋을 차원 축소한 시각화 결과임

➤ 이런 알고리즘은 가능한 한 구조를 그대로 유지함으로 데이터가 어떻게 조직되어 있는지 이해할 수 있음

➔ 또한, 예상하지 못한 패턴을 발견할 수도 있음



t-SNE으로 MNIST  
손글씨 숫자 데이터셋을  
차원 축소한 시각화



## 03 | 비지도 학습

### 비지도 학습(Unsupervised Learning)

△ 차원 축소(dimensionality reduction) 알고리즘의 사용 예시


◆ 차원 축소는 너무 많은 정보를 잃지 않으면서 데이터를 간소화하는데 사용됨

▶ 차원 축소 방법으로 상관관계가 있는 여러 특성을 하나로 합치는 것임

— 예를 들어 차의 주행거리는 연식과 매우 연관되어 있음

→ 그러므로, 차원 축소 알고리즘은 두 특성을 차의 마모 정도를 나타내는 하나의 특성으로 합칠 수 있음

→ 이를 특성 추출(Feature Extraction)이라고 부름



[차원 축소]



## 03 | 비지도 학습



### 비지도 학습(Unsupervised Learning)

- ❖ [차원 축소의 이점] 기계학습 알고리즘에 데이터를 주입하기 전에 차원 축소 알고리즘을 사용하여 훈련 데이터의 차원을 줄이는 것이 유용할 때가 많음
- ◆ 훈련 데이터의 차원을 줄이면 다음과 같은 이점이 있음
  - 실행 속도가 훨씬 빨라짐
  - 디스크와 메모리를 차지하는 공간도 줄일 수 있음
  - 자연스럽게 성능도 좋아짐






## 03 | 비지도 학습



### 비지도 학습(Unsupervised Learning)

△ 이상치 탐지(outlier detection) 알고리즘의 사용 예시

- ◆ 이상치 탐지 학습 알고리즘은 훈련하는 동안 대부분 정상 샘플을 만나 이를 인식하도록 훈련됨
  - 그 다음 새로운 샘플을 보고 정상 데이터인지 혹은 이상치인지 판단함





## 03 | 비지도 학습



### 비지도 학습(Unsupervised Learning)

- ◆ 이상치 탐지 활용의 예를 들면 다음과 같음
  - 부정 거래를 막기 위해 **이상한 신용카드 거래**를 감지함
  - **제조 결함**을 찾아냄
  - 학습 알고리즘에 주입하기 전에 **데이터셋**에서 **이상한 값**을 **자동**으로 **제거**함



## 03 | 비지도 학습



### 비지도 학습(Unsupervised Learning)

△ 연관 규칙 학습 알고리즘의 사용 예시

◆ 연관 규칙 학습은 대량의 데이터에서 특성 간의 흥미로운 관계를 찾음

➢ 어떠한 상품을 구매한 사람이 다른 상품을 구매하는 경향이 있다는 것을 찾을 때 활용함

➢ 아래 그림처럼 우유를 산 고객이 식빵을 함께 구매하는 경향이 있다는 것을 찾을지도 모름

연관규칙분석은 아래와 같은 조건부 확률을 구하는 것



우유를 산 고객이

식빵을 함께 구매할 확률(비율)	80%
계란을 함께 구매할 확률(비율)	60%
휴지를 함께 구매할 확률(비율)	45%



## 04 | 준지도 학습



### 준지도 학습(Semisupervised Learning)

- △ 준지도 학습은 레이블이 일부만 있어도 데이터를 다룰 수 있음
  - ◆ 데이터에 레이블을 다는 것은 일반적으로 시각과 비용이 많이 들기 때문에 레이블이 없는 샘플이 많고 레이블된 샘플은 적은 경우가 많음
    - 어떤 알고리즘은 일부만 레이블이 있는 데이터를 다룰 수 있음
      - ─ 이를 준지도 학습이라고 부름



## 04 | 준지도 학습

### 준지도 학습(Semisupervised Learning)

△ 예를 들면 구글 포토 호스팅 서비스

◆ 이 서비스에 가족사진을 모두 올리면 **사람 A**는 **사진 1, 5, 11**에 있음

‣ **사람 B**는 **사진 2, 5, 7**에 있다고 **자동으로 인식**(군집, Clustering)함

‣ 시스템이 필요한 것은 **이 사람**이 **누구인지** 하는 **정보**임

— **사람마다 레이블이 하나씩만 주어지면**(지도 학습) **사진**에 있는 **모든 사람**의 **이름**을 **알 수 있음**

➔ 이 정보를 이용하면 **편리하게 사진**을 **찾을 수 있음**







## 05 | 강화 학습



### 강화 학습(Reinforcement Learning)

△ 강화 학습은 매우 다른 종류의 알고리즘임

◆ 학습하는 시스템을 에이전트(Agent)라고 부름

‣ 환경(Environment)을 관찰해서 행동(Action)을 실행하고 보상(Reward)을 받음

‣ 시간이 지나면서 가장 큰 보상을 얻기 위해 정책(Policy)이라고 부르는 최상의 전략을 스스로 학습함

– 정책은 주어진 상황에서 에이전트가 어떤 행동을 선택해야 할지 정의함



## 05 | 강화 학습

### 강화 학습(Reinforcement Learning)

△ 예를 들어 보행 로봇을 만들기 위해 강화 학습 알고리즘을 많이 사용함

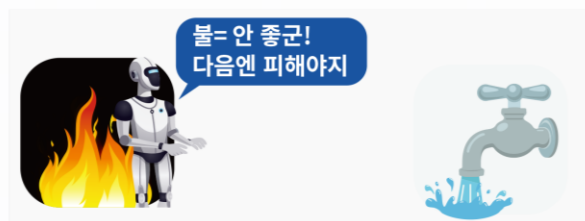
◆ 아래의 그림은 강화 학습의 학습 과정을 나타냄



- ① 관찰
- ② 정책에 따라 행동을 선택



- ③ 행동 실행!
- ④ 보상이나 벌점을 받음



- ⑤ 정책 수정 (학습 단계)
- ⑥ 최적의 정책을 찾을 때까지 반복

[강화 학습 예시]



## 05 | 강화 학습

### 강화 학습(Reinforcement Learning)

△ 딥마인드(DeepMind)의 알파고(AlphaGo) 프로그램도 강화 학습의 좋은 예임

◆ 2017년 5월 바둑 세계 챔피언인 커제 선수를 이겨서 신문의 헤드라인을 장식했음

➢ 알파고는 수백만 개의 게임을 분석해서 승리에 대한 전략을 학습했음

➢ 그리고, 자기 자신과 많은 게임을 했음

➔ 알파고가 세계 챔피언과 게임할 때는 학습 기능을 끄고 그동안 학습했던 전략을 적용한 것임



[알파고]



## 06 | 배치 학습



### 배치 학습(Batch Learning)

⚠ 배치 학습은 시스템이 점진적으로 학습할 수 없음

◆ 가용한 데이터를 모두 사용해 훈련시켜야 하는 방식임

➤ 일반적으로 이 방식은 시간과 자원을 많이 소모하므로 오프라인에서 수행함

➤ 먼저, 시스템을 훈련시키고 그런 다음 제품 시스템에 적용하면 더 이상의 학습 없이 실행됨

— 즉, 학습한 것을 적용만 수행함

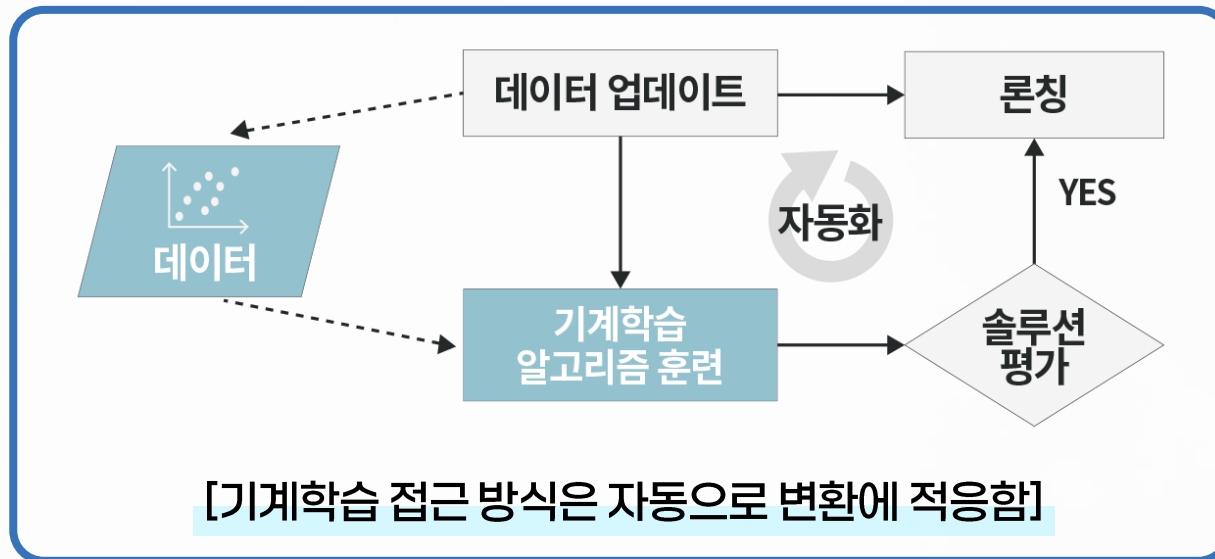
➔ 이를 오프라인 학습(Offline Learning)이라고도 부름



## 06 | 배치 학습

### 배치 학습(Batch Learning)

- ◆ 아래 그림과 같이 **기계학습 시스템**을 훈련, 평가, 론칭하는 **전체 과정**이 쉽게 **자동화**될 수 있어서 **배치 학습 시스템**도 **데이터 변화**에 **적응**할 수 있음
  - 데이터를 **업데이트**하고 **시스템의 새 버전**을 필요한 만큼 **자주 훈련**시키면 **해결**됨
  - 갱신 주기는 보통 **24시간**마다 또는 **매주** 시스템을 훈련시킴







## 06 | 배치 학습



### 배치 학습(Batch Learning)

- ◆ 전체 데이터셋을 사용해 훈련한다면 많은 컴퓨터 자원이 필요함
  - 대량의 데이터를 가지고 있는데 매일 처음부터 새로 훈련하도록 자동화하면 큰 비용이 발생할 것임
    - ▣ 데이터 양이 아주 많으면, 배치 학습 알고리즘을 사용하는 게 불가능할 수도 있음
      - ❖ 예를 들어 스마트폰 또는 화성 탐사 로봇 등이 스스로 학습해야 할 때 많은 양의 훈련 데이터를 학습하는 경우 심각한 문제를 일으킬 수 있음
        - ➔ 이런 경우에는 점진적으로 학습할 수 있는 알고리즘을 사용하는 편이 바람직함

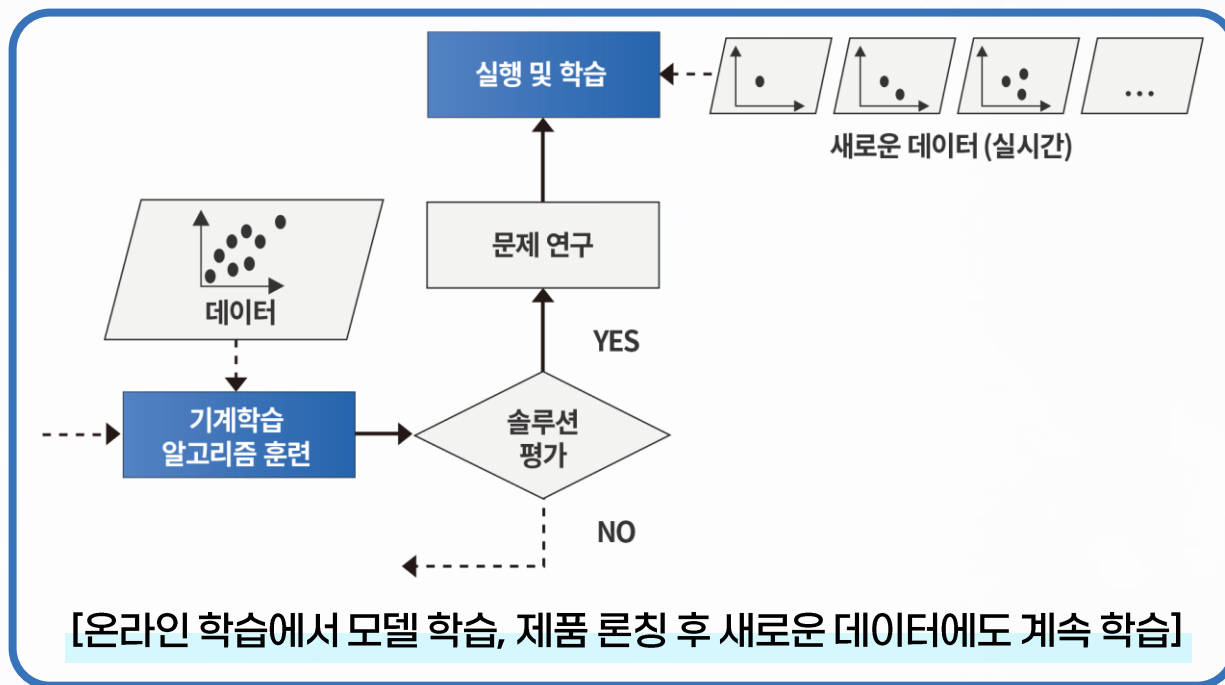


## 07 | 온라인 학습 (미니배치 학습)

### 🔧 온라인 학습(Online Learning) 또는 미니배치 학습

⚡ 온라인 학습은 데이터를 순차적으로 한 개씩 또는 미니배치(Mini-Batch)라 부르는 작은 묶음 단위로 주입하여 시스템을 훈련시키는 방식임

◆ 매 학습 단계가 빠르고 비용이 적게 들어 시스템은 데이터가 도착하는 대로 즉시 학습할 수 있음





## 07 | 온라인 학습 (미니배치 학습)

### 온라인 학습(Online Learning) 또는 미니배치 학습

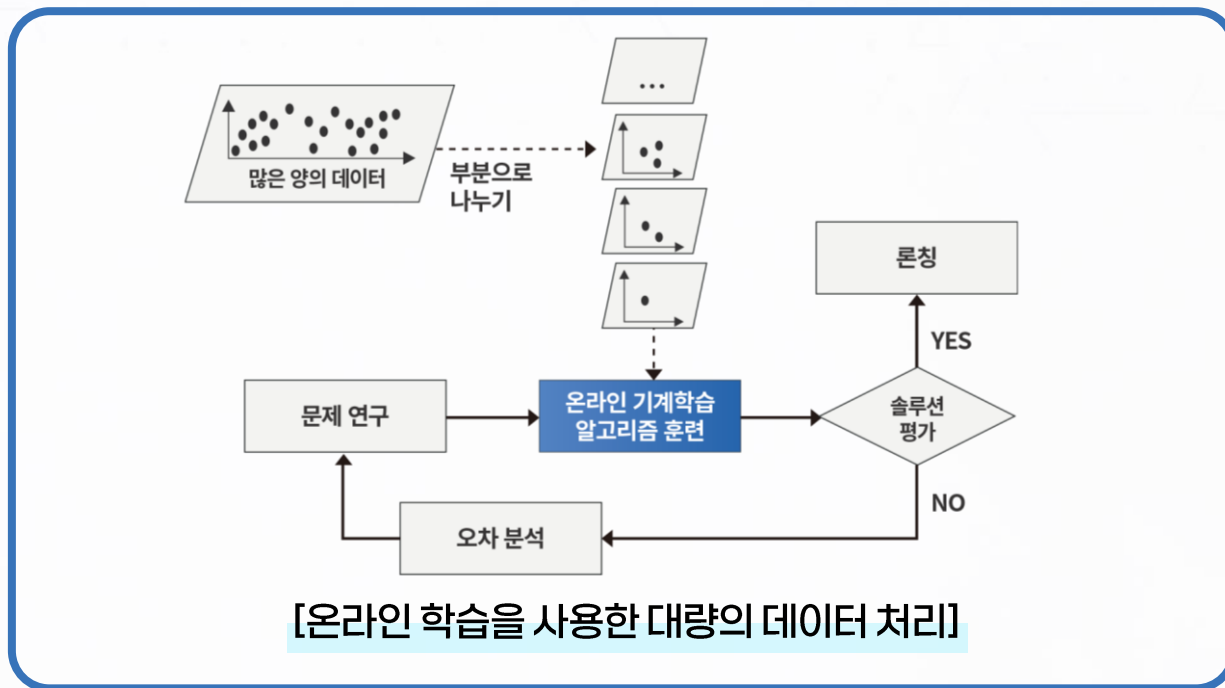
- ◆ 온라인 학습은 연속적으로 데이터를 받고 빠른 변화에 스스로 적응해야 하는 시스템에 적합함
    - ▶ 컴퓨팅 자원이 제한된 경우에도 좋은 선택임
    - ▶ 온라인 학습은 컴퓨터 한 대의 메인 메모리에 들어갈 수 없는 아주 큰 데이터셋을 학습하는 시스템에도 사용할 수 있음
      - ─ 이를 외부 메모리(out-of-core) 학습이라고 부름
      - ─ 알고리즘이 데이터 일부를 읽어 들이고 훈련 단계를 수행함
        - ❖ 전체 데이터가 모두 적용될 때까지 이 과정을 반복함
- ❖ 외부 메모리 학습은 보통 오프라인으로 실행됨
  - ❖ 그래서 온라인 학습이란 이름이 혼란을 줄 수 있으며, 점진적 학습(incremental learning)이라고 이해하면 됨



## 07 | 온라인 학습 (미니배치 학습)

### 🔧 온라인 학습(Online Learning) 또는 미니배치 학습

➤ 아래의 그림은 온라인 기계학습 알고리즘이 대량의 데이터를 작은 묶음 단위로 나누어 반복적으로 학습하는 과정을 나타냄

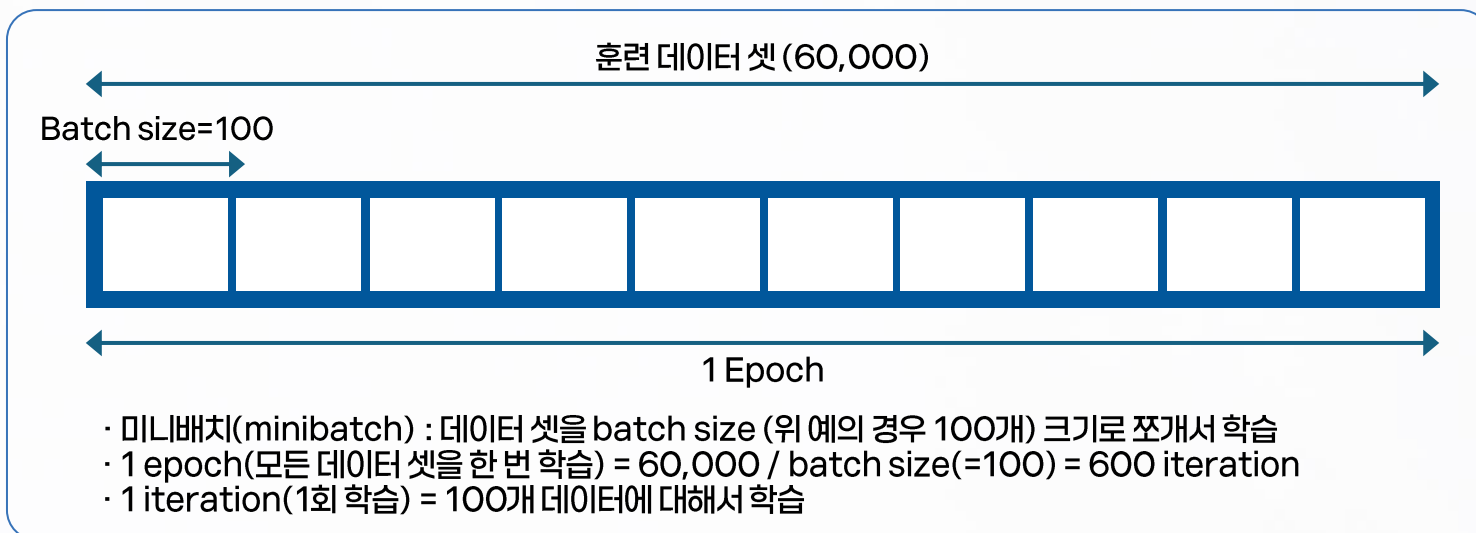




## 07 | 온라인 학습 (미니배치 학습)

### 🔧 온라인 학습(Online Learning) 또는 미니배치 학습

- ◆ 예를 들어 60,000장의 훈련 데이터 중에서 100장을 무작위로 뽑아 그 100장만을 사용하여 학습하는 것임
  - 이러한 학습 방법을 미니배치 학습이라고 부름
  - MNIST 데이터셋에서 훈련 데이터 60,000개를 100개의 미니배치로 학습할 경우, 600회 반복하면 모든 훈련 데이터를 '소진'하게 됨
    - 이 경우 600회가 1 에폭(epoch)이 됨

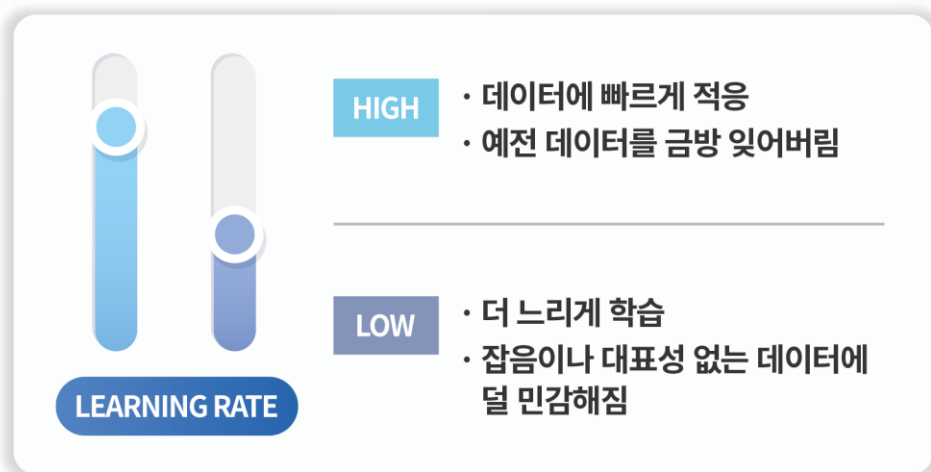




## 07 | 온라인 학습 (미니배치 학습)

### 🔧 온라인 학습(Online Learning) 또는 미니배치 학습

- ◆ 온라인 학습 시스템에서 **중요한 파라미터** 중 하나는 **변화하는 데이터에 얼마나 빠르게 적응할 것인지**
  - 이를 **학습률**(learning rate)이라고 부름
    - 학습률을 **높게 하면** 시스템이 **데이터에 빠르게 적응**하지만 **예전 데이터**를 **금방 잊어버리게** 됨
    - 학습률이 **낮으면** 시스템의 관성이 더 커져서 **더 느리게 학습**되지만 **새로운 데이터에 있는 잡음**이나 **대표성 없는 데이터 포인트**에 **덜 민감해**짐





## 07 | 온라인 학습 (미니배치 학습)

### 온라인 학습(Online Learning) 또는 미니배치 학습

◆ 온라인 학습의 가장 큰 문제점은 다음과 같음

➤ 시스템에 나쁜 데이터가 주입되었을 때 시스템 성능이 점진적으로 감소한다는 점임

➤ 운영 중인 시스템이라면 고객이 눈치챌지 모름

➤ 예를 들어 로봇의 오작동 센서에서부터, 혹은 검색 엔진을 속여  
검색 결과 상위에 노출시키려는 누군가로부터 나쁜 데이터가 주입될 수 있음

❖ 이런 위험을 줄이려면 시스템을 면밀히 모니터링하고  
성능 감소가 감지되면 즉각 학습을 중지시켜야 함

➔ 입력 데이터를 모니터링해서 비정상 데이터를 잡아낼 수도 있음





## 08 | 사례 기반 학습과 모델 기반 학습



### 사례 기반 학습과 모델 기반 학습

- ◆ 기계학습 시스템은 어떻게 일반화(generalize) 되는가에 따라 분류할 수 있음
  - ▶ 대부분의 기계학습 작업은 예측을 만드는 것임
    - 즉, 주어진 훈련 데이터로 학습하고 훈련 데이터에서는 본 적 없는 새로운 데이터에서 좋은 예측을 만들어야 한다는 뜻임
      - ❖ 훈련 데이터에서 높은 성능을 내는 것이 좋지만 그게 전부는 아님
      - ❖ 진짜 목표는 새로운 샘플에 잘 작동하는 모델임
- ➔ 일반화를 위한 두 가지 접근법은 사례 기반 학습과 모델 기반 학습임



## 08-1 | 사례 기반 학습



### 사례 기반 학습 (Instance-Based Learning)

- ◆ 시스템이 사례를 기억함으로써 학습하는 방식임
  - 스팸 필터를 이러한 방식으로 만들면 사용자가 스팸이라고 지정한 메일과 동일한 모든 메일을 스팸으로 분류함
    - ─ 이것은 최악의 방법도 아니지만 최선도 아님





## 08-1 | 사례 기반 학습

### 사례 기반 학습 (Instance-Based Learning)

- ◆ 스팸 메일과 동일한 메일을 스팸이라고 지정하는 대신  
스팸 메일과 매우 유사한 메일을 구분하도록 스팸 필터를 프로그램할 수 있음
    - 이렇게 하려면 두 메일 사이의 유사도(Similarity)를 측정해야 함
      - ─ 두 메일 사이의 매우 간단한 유사도 측정 방법은 공통으로 포함한 단어의 수를 세는 것임
        - ❖ 스팸 메일과 공통으로 가지고 있는 단어가 많으면 스팸으로 분류함
- ➔ 이것을 사례 기반 학습이라고 부름



## 08-1 | 사례 기반 학습



### 사례 기반 학습 (Instance-Based Learning)

◆ 시스템이 **훈련 샘플**을 **기억함**으로써 **학습**을 할 수 있음

➢ 유사도 측정을 사용해 **새로운 데이터**와 **학습한 샘플**을 **비교하는 식**으로 **일반화**함

➢ 아래 그림에서 **새로운 샘플**은 **가장 비슷한 샘플 중 다수가 원형**이므로 **원형 클래스**로 **분류될 것임**



[사례 기반 학습 예시]




## 08-2 | 모델 기반 학습



### 모델 기반 학습(Model-Based Learning)

- ◆ 샘플로부터 일반화시키는 다른 방법은 이 샘플들의 모델을 만들어 예측하는 것임
  - 이를 모델 기반 학습이라고 부름






## 08-2 | 모델 기반 학습

### 모델 기반 학습(Model-Based Learning)

- ◆ 모델 기반 학습은 현재 기계학습 트렌드의 대부분을 차지하며, 기계학습의 시작점이라고 해도 과언이 아님
  - ▶ 쉽게 말해서 여러 샘플 데이터들의 모델을 만들어 사용하는 방식임
    - └ 즉, 현재 상태를 어떠한 시각으로 바라보고 어떠한 기대를 하고 있는가를 모델로 나타냄



[기계학습]



## 08-2 | 모델 기반 학습



### 모델 기반 학습(Model-Based Learning)

- ◆ 모델이란 가정(데이터 자체에 대한 믿음)에 따라 생성될 수 있는 함수의 집합임
  - ▶ 기계학습에서 모델을 변경한다는 것은 다음을 의미함
    - ─ 어떤 함수의 꼴을 완전히 변경시키는 것을 의미함
    - ─ 정해진 함수 안에서  $w$ ,  $b$ 와 같은 함수의 파라미터를 데이터를 통해 추측하는 것임
  - ─ 그 모델이 표현하는 함수 집합 중에서 가장 데이터에 적합한 함수를 고르는 과정을 학습이라고 하는 것임





## 08-2 | 모델 기반 학습



### 모델 기반 학습(Model-Based Learning)

◆ 모델은 기계학습의 핵심이라고 할 수 있는데, 이는 기계학습(모델 기반 학습)의 과정을 통해 확인할 수 있음

▶ 기계학습(모델 기반 학습)의 작업 과정을 요약하면 다음과 같음

1

데이터를 분석함

❖ 데이터 특성을 이해함

2

모델을 선택함

3

훈련 데이터로 모델을 훈련시킴

❖ 즉, 학습 알고리즘이 비용 함수를 최소화하는 모델 매개변수를 찾음

4

새로운 데이터에 모델을 적용해 예측을 수행함(추론)

❖ 이 모델이 잘 일반화되길 기대함



## 09 | 인공지능, 머신러닝, 딥러닝



### 인공지능, 머신러닝, 딥러닝

- ◆ 인공지능은 아래 그림처럼 **머신러닝**과 **딥러닝** 두 가지로 구분할 수 있음
  - ▶ 인공지능의 **상업적 발전**을 위해 **머신러닝**이 **매우 중요한 역할**을 하고 있음

