

강원지역혁실플랫폼

기계학습

Machine Learning

K-최근접 이웃 알고리즘



▼ 학습목표

- 📁 K-최근접 이웃 알고리즘을 이해하고 구현할 수 있습니다.





01 | K-최근접 이웃(K-NN) 알고리즘



K-최근접 이웃(K-Nearest Neighbor, K-NN)

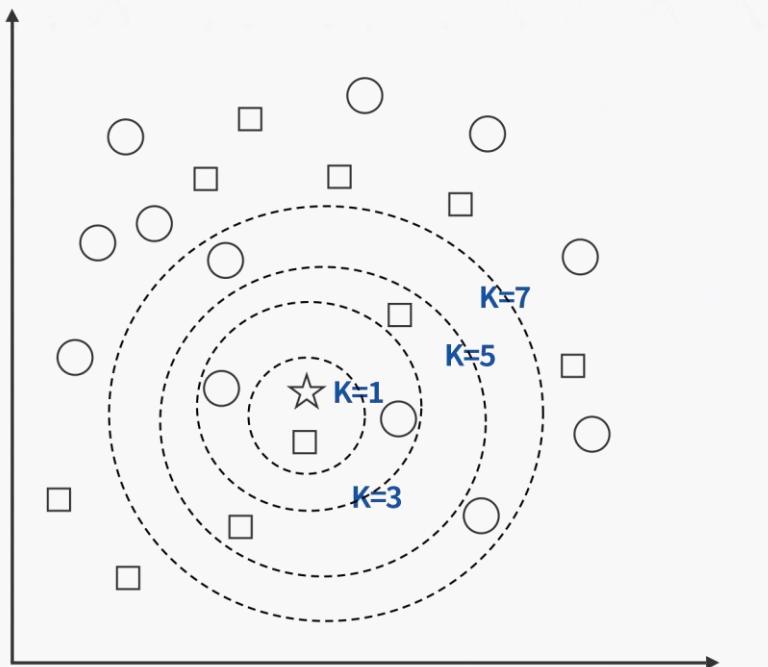
△ K-최근접 이웃 알고리즘은 **비슷한 특성을 가진 데이터는 비슷한 범주에 속하는 경향이 있다**는 가정 하에 사용함

- ◆ 이 알고리즘은 가장 간단한 기계학습 알고리즘임
 - 그리고, **분류(classification)** 알고리즘임



01 | K-최근점 이웃(K-NN) 알고리즘

아래 그림과 같이 주변의 가장 가까운 K개의 데이터를 보고
 데이터가 속할 그룹을 판단하는 알고리즘이 K-NN 알고리즘임

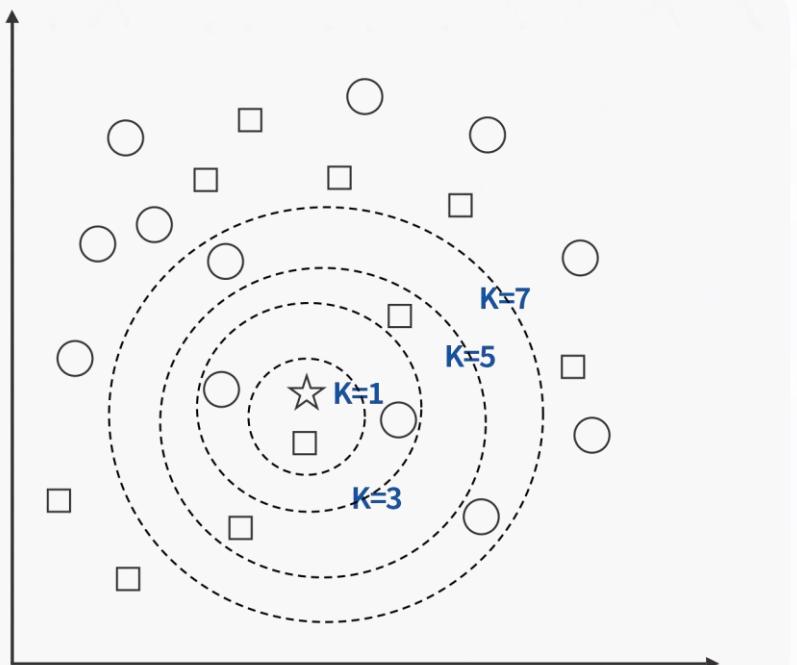




01 | K-최근점 이웃(K-NN) 알고리즘

❖ 아래의 그림처럼 **새로운 데이터**가 **들어왔을 때**를 가정해보자.

- ◆ 기존 데이터와 비교하여 **가장 가까운 K개의 이웃의 정보**를 **기반**으로 **새로운 데이터**를 **예측**함
 - 아래 그림에서 **새로운 데이터**는 ☆ 임

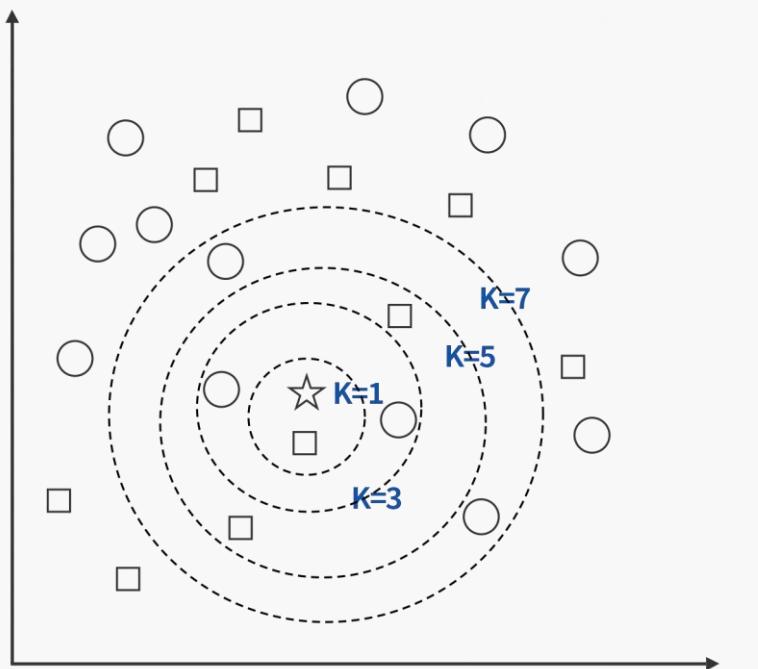




01 | K-최근점 이웃(K-NN) 알고리즘

▲ K-최근점 이웃 알고리즘은 **새로운 데이터 점**(아래 그림에서 ☆)과 **주변 데이터** 세트 간의 **유사성**(similarity)을 측정하여 **최종적으로** **목표변수**의 범주를 **분류**할 때,
몇 개를 기준(K=?)으로 **주변 데이터** 세트를 **판단할 것인가**에 대한 **기준**이 **필요**함

◆ 아래 그림은 K=1, K=3, K=5, K=7인 경우의 K-NN 기법의 예시임

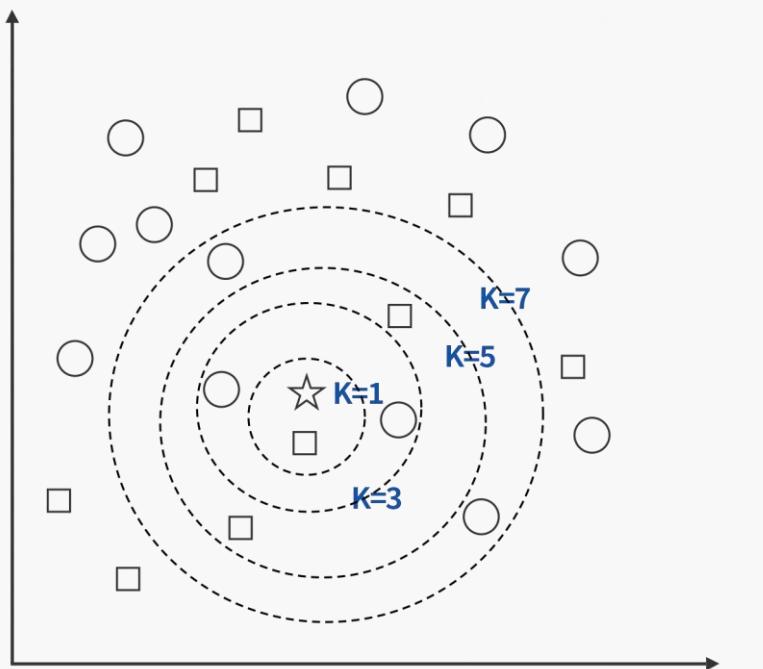




01 | K-최근점 이웃(K-NN) 알고리즘

▲ K-최근점 이웃 알고리즘은 **새로운 데이터 점**(아래 그림에서 ☆)과 **유사한 K개의 주변 데이터 점**에서 **다수결의 원칙**에 따라 **새로운 범주를 결정하는 방식**임

◆ 아래 그림에서 **새로운 데이터 ‘☆’**가 **다수결의 원칙**에 따라 ‘□’ 또는 ‘○’로 **분류됨**





01 | K-최근점 이웃(K-NN) 알고리즘

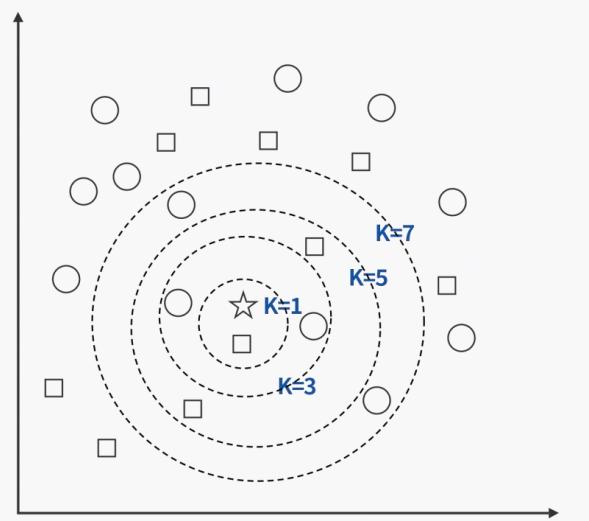
▲ 아래 그림은 K-NN에서 $K(=1,3,5,7)$ 값 설정에 따른 목표변수 값 변화를 개념적으로 표현하였음

◆ ‘☆’은 새롭게 분류해야 할 데이터 값이고, ‘□’와 ‘○’는 주변에 존재하는 데이터 값임

› 여기서 $K=1$ 로 설정하면, ‘☆’과 가장 가까운 데이터 값은 ‘□’이므로 ‘☆’의 목표변수는 ‘□’로 분류됨

› 이것을 반복하여 $K=3$, $K=5$, $K=7$ 로 설정하면, 다수결의 원칙에 의하여 ‘☆’의 목표변수를 예측 분류할 수 있음

› 여기서 주목할 점은 K 값을 어떻게 정하느냐에 따라 목표변수의 범주 예측 결과가 크게 달라질 수 있다는 것임





01 | K-최근접 이웃(K-NN) 알고리즘

❖ K-NN 기법에서 적절한 K값을 정하는 것이 매우 중요함

- ◆ K가 작을 경우 데이터의 지역적 특성을 지나치게 반영하여 과적합이 발생함
 - 반대로, K가 너무 클 경우 모델이 지나치게 정규화되어 과소적합이 발생할 수 있음
 - ─ 여기서 적절한 K를 선택하기 위한 방법을 생각해 보자.



01 | K-최근접 이웃(K-NN) 알고리즘

- ❖ 적절한 K를 선택하기 위해서는 훈련 데이터 셋과 테스트 데이터 셋을 나눔
 - ◆ K를 바꿔가면서 실험을 거쳐 최적의 K를 찾아야 함
 - 다만 K값은 관측치의 개수 보다는 작은 것이 좋다고 알려져 있음
 - 일반적으로 K=3에서 K=9사이의 범위 내에서 분류 성능을 테스트해보면서 최적의 K값을 정하는 방법을 사용하기도 함

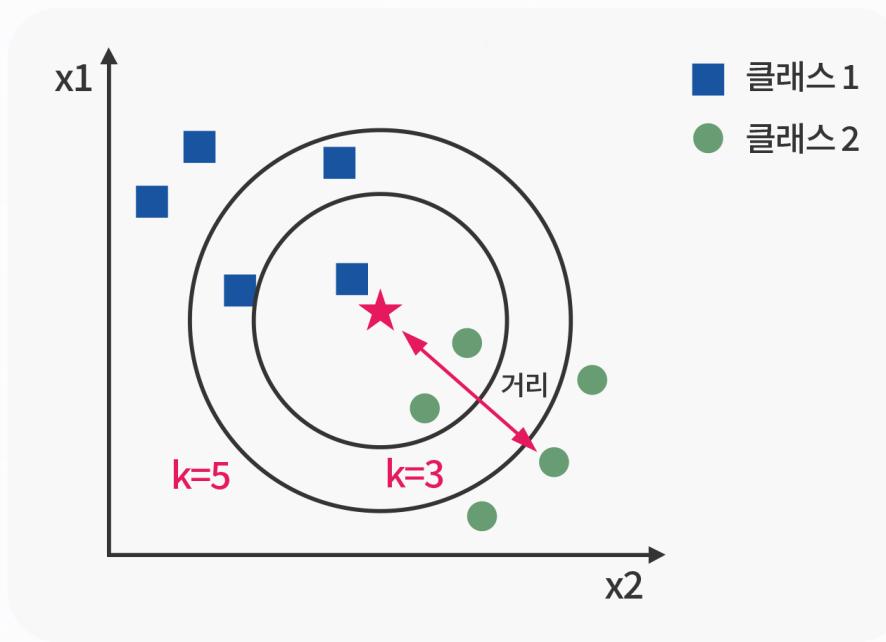


01 | K-최근접 이웃(K-NN) 알고리즘

▲ K-NN에서 **거리 측정 방법**은 또 하나의 하이퍼파라미터(Hyper-parameter)이며 **거리를 측정하는 방법**에 따라 **결과가 크게 달라짐**

- ◆ 거리 측정 방법에는 유클리디안(Euclidean), 맨해튼(Manhattan), 마할라노비스(Mahalanobis)거리 등이 있음

› 일반적으로 **거리를 측정할 땐 유클리드 거리**(Euclidean distance)를 **주로 사용함**



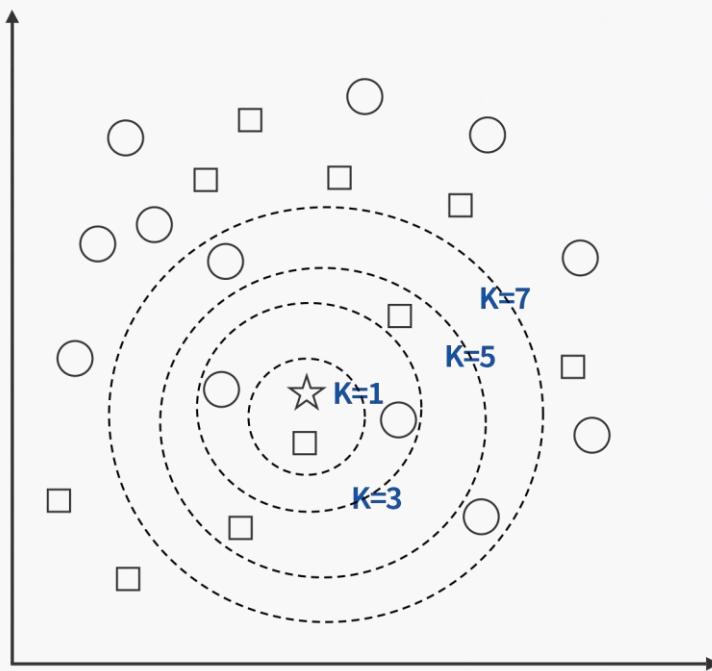


01 | K-최근접 이웃(K-NN) 알고리즘

▲ K-최근접 이웃(K-NN) 모델의 특징

◆ K-NN의 특징은 학습이 따로 필요 없다는 것임

› 새로운 데이터가 주어지면 그때 기존 데이터에서 가까운 이웃을 뽑고 예측할 뿐임





01 | K-최근점 이웃(K-NN) 알고리즘

▲ K-NN 알고리즘의 장 · 단점

구 분	설 명
장 점	<ul style="list-style-type: none">❖ 알고리즘이 이해하기 쉽고 직관적이다.❖ 데이터 세트의 확률분포 등에 대한 가정이 필요하지 않다.❖ 사전 모형 설정 및 모수 추정이 필요 없다(비모수 방식).❖ 훈련(학습) 시간이 빠르다.❖ 노이즈 데이터의 영향을 크게 받지 않는다(Robust하다).❖ 분류 뿐만 아니라 회귀 문제에도 K-NN 방법론을 적용할 수 있다.
단 점	<ul style="list-style-type: none">❖ K값에 대한 명확한 기준이 없어 시행착오적 접근이 필요하다.❖ 특정한 가설이나 모형 없이 주어진 데이터를 통해 범주의 분류 결과만 판단함으로 분석을 통한 통찰력을 얻기 어렵다.❖ 새로운 데이터가 주어질 때마다 모든 데이터와의 유사도를 계산해야 함으로 그만큼 시간 소요가 많다 (이런 특성 때문에 게으른 학습(Lazy learning)으로 불림).❖ 데이터 세트의 모든 데이터들과 거리 계산을 위해 메인 메모리에 가져와야 함으로 많은 메모리가 필요하다.



01 | K-최근접 이웃(K-NN) 알고리즘

▲ K-NN 알고리즘으로 학습하기 전에는 변수의 범위(scale)를 축소해야 함

- ◆ 변수마다 측정 범위가 다를 경우에 범위가 큰 변수가 모델에 과도하게 큰 영향을 미침
 - › 따라서, 범위가 작은 변수는 무시될 수 있기 때문임



01 | K-최근접 이웃(K-NN) 알고리즘

❖ 예를 들어 다음과 같은 **가상 데이터**가 있다고 **가정하자.**

- ◆ 아래 표를 기준으로는 거리를 측정할 때 **직원 수 정보**는 전혀 **반영되지 않을 것**임
 › **직원 수 단위가 매출의 단위보다 훨씬 작기 때문**임

매출(원)	직원 수(명)	분류
50,000,000	20	A
55,000,000	40	A
60,000,000	50	A
70,000,000	30	B
30,000,000	60	B
75,000,000	70	B



01 | K-최근접 이웃(K-NN) 알고리즘

❖ 아래의 데이터로 K-NN모델을 만들면 매출에 강한 영향을 받게 됨

- ◆ 따라서, 각 변수의 값의 범위를 동등하게 조정해야 함
 - 변수 별로 평균과 분산을 일치시키는 등의 정규화 작업이 필요함

매출(원)	직원 수(명)	분류
50,000,000	20	A
55,000,000	40	A
60,000,000	50	A
70,000,000	30	B
30,000,000	60	B
75,000,000	70	B



01 | K-최근접 이웃(K-NN) 알고리즘

▲ 데이터의 값 범위를 변환하는 것을 스케일링(scaling) 또는 정규화라고 하며
자주 사용되는 정규화 방법은 다음과 같음

① 최대최소 스케일링(MinMax Scaling)

› 모든 변수의 값을 0~1 사이에 위치하도록 조정함

- 새로운 데이터 x' 는 원래 값 x_i 에서 변수 x 의 최솟값을 뺀 값을
변수 x 의 최대값과 최솟값의 차이로 나눈 값으로 변환한 것임

$$x' = \frac{x_i - \min(x)}{\max(x) - \min(x)}$$



01 | K-최근접 이웃(K-NN) 알고리즘

2 표준정규분포로 표준화(Standardization)

- › 곱셈과 덧셈만으로 **변환**하는 **선형변환**을 통해 **각 특성의 평균을 0, 분산을 1로 변경**하여 모든 특성이 같은 크기를 가지게 함
 - 그러나, 이 방법은 특성은 **최소값**과 **최대값** 크기를 제한하지는 않음
 - 새로운 데이터 x' 는 **원래 값**에서 변수 x 의 **평균을 뺀 값**을 변수 x 의 **표준편차**(STDEV, Standard Deviation)로 **나눈 값**으로 **변환**한 것임
- ➔ 이 값을 **표준점수** 혹은 **Z-점수**(Z-Score)라고 부름

$$x' = \frac{x_i - \text{mean}(x)}{\text{STDEV}(x)}$$